Deep learning lab3 陳品翰 report

1. Introduction (5%)

這份 lab 在一開始會用 VQGAN encoder 把圖片轉成 token,之後讓 transformer 去學習 token 之間的相互關係,讓 transformer 可以還原圖片, 最後把 transformer 的 output 傳給 VQGAN 的 decoder,讓他還原圖片。

- 2. Implementation Details
 - A. The details of your model(Multi-Head Self-Attention)

```
Class MultiHeadAttention(m.Module):


def _int_(self, dia=768, num_heads=16, attn_drop=0.1):
    super(MultiHeadAttention, self)._init_()
    self.num_heads = num_heads
    self.head_dim = dim // num_heads = 每個 head 的細胞:768 // 16 = 48
    self.scale = self.head_dim **-0.5 # 用來館 scaled dot-product

# 三個性母:0, K, V 對極入機能性形態
    self.k_proj = nn.Linear(dim, dim)
    self.k_proj = nn.Linear(dim, dim)
    self.k_proj = nn.Linear(dim, dim)
# 合併所質 head 之後的健性層
self.out_proj = nn.Linear(dim, dim)
# dropout for attention ueights
self.attn_drop = nn.Dropout(attn_drop)
```

Multihead__init__():先計算每個 head 的維度,之後建立三個線性層, 最後再合併後 dropout

Forward:會得到三個值,分別為 q、k、v,之後把它們 reshape 以後,讓每個 head 有自己的 q、k、v,之後每個 head 做 dot-product,之後加權求和得到 context vector,最後合併所有的 head->linear->output。

流程圖:



B. The details of your stage2 training (MVTM, forward, loss)

```
def train_one_epoch(self, train_loader, epoch, device):
self.model.train()
total_loss = 0

pbar = tqdm(train_loader)
for i, data in enumerate(pbar):
x + data.to(device)
logits, target, mask = self.model(x) # (B, 256, 1824), (B, 256), (B, 256)
assert (target < self.wocab_size - 1).all(), "target 包含 mask_token_id!"
# FURTHERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTERMENTE
```

```
optimizer = torch.optim.AdamW(
    self.model.transformer.parameters(),
    lr=self.args.learning_rate,
    betas=(0.9, 0.95),
    weight_decay=0.01
)
```

在我的 train_one_epoch 裡面,我會去使用到 model 的 forward,在 forward 裡面,他會把 training 的圖片先 encode 成 token,之後隨機 mask 40%~55%的圖片,之後把原圖片中 mask 的地方改成 mask token(定為 1024),之後去給 transformer 學習,並且 return transformer 預測的結果、原本的 ground truth 跟 mask 的位子給 train_one_epoch,之後 train_one_epoch 會去計算 mask 位子的 loss,我的 Optimizer 是用

Adamw,讓 model 避免 overfitting 並且提升 generalization。 另外,因為我在訓練的時候自己定義了 mask token,所以 codebook 裡面也要加上一個位子給 mask,讓他知道目前的位子為 mask。

```
with torch.no_grad():
    old_weight = self.vqgan.codebook.embedding.weight # 原本的 [1024, dim]
    new_embed = nn.Embedding(self.vocab_size, old_weight.shape[1])
    new_embed.weight[:-1] = old_weight # 保留原本的 embedding
    new_embed.weight[-1].zero_() # 最後一個 index 給 mask token (初始化爲 0)
    self.vqgan.codebook.embedding = new_embed
```

另外我的 transformer 裡面也要有一個位子給 mask,可以看到 tok emb 有加 1

```
class BidirectionalTransformer(nn.Module):
    def _init_(self, configs):
        super(BidirectionalTransformer, self)._init_()
        self.tok_emb = nn.Embedding(configs['num_inage_tokens']
        self.tok_emb = nn.Embedding(configs['num_codebook_vectors'] + 1, configs['dim'])
        self.tok_emb = nn.init.trunc_normal_(nn.Parameter(torch.zeros(configs['num_inage_tokens'], configs['dim'])), 0., 0.02)

        self.blocks = nn.Sequential(*[Encoder(configs['dim'], configs['hidden_dim']) for _ in range(configs['n_layers'])])
        self.token_Prediction = TokenPredictor(configs['dim'], configs['hidden_dim']) for _ in range(configs['n_layers'])])
        self.token_Prediction = TokenPredictor(configs['dim'])
        self.token_Prediction = TokenPredictor(configs['dim']
```


C. The details of your inference for inpainting task

上面的圖片是 inpainting.py 的函式,下面是 VQGAN_Transformer 的 inpainting,當我在畫圖時,會使用 inpainting.py,執行的流程為,一開始先把圖片 encode 成 token 後初始化 z_indices_predict,之後在 iterative 畫圖時,會去呼叫到下面圖片中的 inpainting function,他會 把圖片中 mask 的部分轉換為 mask_token_id,之後去給 transformer 做預測,加上 Gumbel Noise 是為了要讓模型有隨機性,之後選擇最有 信心的 token 先填上,並且依照 gamma function 決定還要剩下多少 mask,之後把預測好的 token 填回去,回到 inpainting.py,最後把 token decode 回圖像。

3. Discussion(bonus: 10%)

在一開始的時候我是把我 train 時候的 mask 都固定設為 60%,但是我發現我的 loss 都會一直卡在 2.8 左右,所以我之後把我的 mask ratio 調整為

0.4~0.6,最後又調整成 0.4~0.55,我的 loss 可以降為 2.0 左右。 下面是我的 loss/epoch 的圖片,因為我是 load model 後又繼續 train,所以圖片有 4 張。



順序為左上、右上、左下、右下。

4. Experiment Score (50%)

Part1: Prove your code implementation is correct (30%)

(a) Mask in latent domain

Cosine:



Linear:



Square:



Logarithm:



(b) Predicted image

Cosine:



Linear:



Square:



Logarithm:



Part2: The Best FID Score (20%)

Sweet point:3 total_iter:8

Score:

